Détection du Stress Académique par Apprentissage Automatique

Axel Bröns[1], Omar El Alami El Fellousse[1], Anas Boutaleb[1], Medeiros Machado Guilherme[1], Belbachir Faiza, Soni Aakash[1]

[1] ECE Ecole d'ingénieurs, 10 Rue Sextius Michel, 75015 Paris

Motivation

Le stress en milieu scolaire n'est plus seulement un obstacle à la réussite ; il est la source de conséquences graves telles que le **décrochage scolaire**, des **pathologies chroniques**, voire des **risques vitaux** pour les étudiants [1].

L'essor de l'intelligence artificielle et l'analyse des signaux physiologiques ouvrent une voie nouvelle pour transformer l'enseignement:

- **Anticiper pour protéger** : Prédire le niveau de stress avant l'épuisement grâce à l'apprentissage automatique.
- **Soutenir l'enseignement** : Offrir aux enseignants des outils de pilotage pour réadapter la charge de travail ou le rythme pédagogique en temps réel.
- **Agir par la donnée** : Passer d'une réaction tardive à une prévention proactive basée sur des données physiologiques objectives.

Notre méthodologie

- **Sujets:** 3 étudiants
- **Matériel:** BITalino (R)evolution, capteurs ECG et EDA
- **Déroulement:** 5 min de calme / 5 min de stress cognitif / 5 min de sport
- **Logiciel:** Acquisition via OpenSignals, traitement via NeuroKit2 en Python

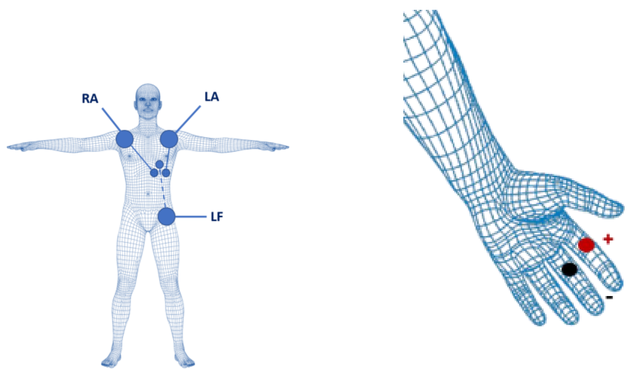

(a) ECG (b) EDA

Figure 1. Placement de nos capteurs

Stress Cognitif

- Jeux d'échecs en ligne avec cadence 1 min par joueur
- Mémoire de longues série de chiffres (sous contrainte de temps)

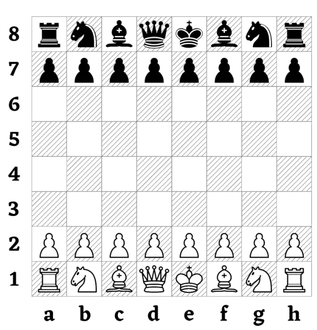

Figure 2. Exemple de jeux d'échecs pour provoquer le stress cognitif

Expérimentation

1. Le Fenêtrage

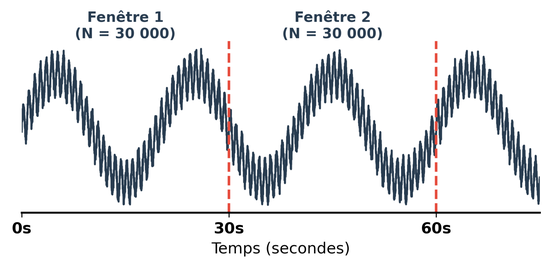

$$W_i = \{x[n] \mid i \cdot N \leq n < (i+1) \cdot N\}$$

Figure 3. Fenêtrage sur un signal artificiel avec un découpage de $T = 30s$ (soit $N = 30\,000$ car $f_s = 1000Hz$). Le signal est segmenté en fenêtres disjointes W_i.

2. Feature Extraction

Catégorie	Features (Signaux)
ECG	HR_Mean, HRV_RMSSD, HRV_pNN50
EDA	EDA_Mean, SCR_Peaks, SCR_Amplitude_Mean

Table 1. Extraction des caractéristiques physiologiques.

3. Pipeline

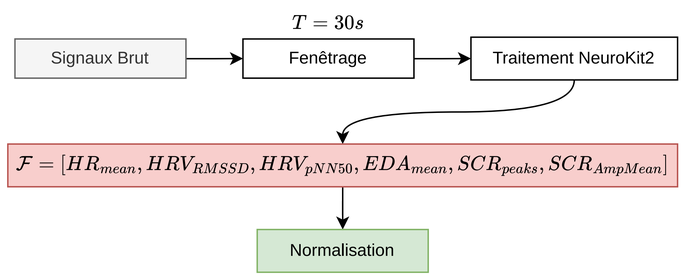

$$z_{i,j,k} = \frac{x_{i,j,k} - \mu_{i,k}}{\sigma_{i,k}}, \forall i \in \mathcal{S}, \forall j \in \mathcal{W}_i, \forall k \in \mathcal{F}$$

Figure 4. Pipeline de la data preparation, avec $\mathcal{S}$ l'ensemble des sujets, $\mathcal{F}$ l'ensemble des features et $\mathcal{W}_i$ l'ensemble des indices des fenêtres du sujet i

4. Leave-One-Group-Out (LOGO) [2]

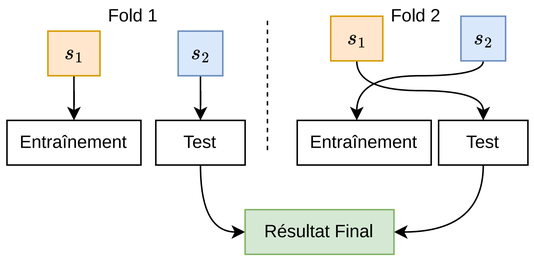

Figure 5. Validation LOGO, avec $\mathcal{S} = \{s_1, s_2, \ldots, s_N\}$ l'ensemble des sujets et ici $N = 2$ donc $N = k$ avec k le nombre de folds

Résultats

Table 2. Comparaison des performances des modèles de classification

Modèle	Accuracy	Precision	Recall	F1-Score
SVM (RBF)	66.10	64.77	66.05	64.66
Régression Logistique	69.49	71.44	69.65	69.57
SVM (Linéaire)	71.19	71.86	71.23	70.99
Random Forest	83.05	84.39	83.33	82.91
XGBoost	84.75	86.79	85.00	84.26
CatBoost [3]	**88.14**	**89.78**	**88.33**	**88.15**

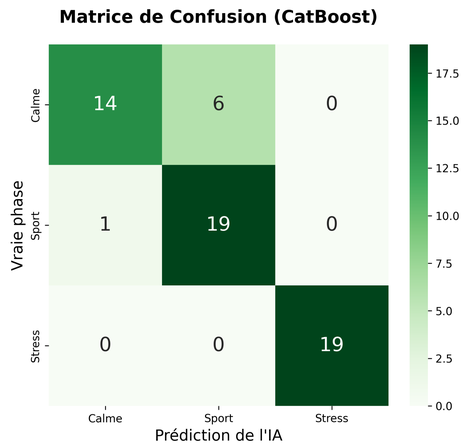

Figure 6. Matrice de confusion pour l'algorithme **CatBoost**

Conclusion & Perspectives

Bilan

- Capacité de généralisation pour d'autres sujets
- Preuve de concept validée avec matériel BITalino

Limitation

- Echantillon restreint (3 étudiants)
- Environnement de laboratoire (cadence de test de 5 min)

Travaux Futurs

- Ajouter des échantillons pour la base de données
- Appliquer dans de vrais conditions de classe

References

[1] Sannyuya Liu, Yunhan Zhang, Liang Zhao, and Zhi Liu. Academic stress detection based on multisource data: a systematic review from 2012 to 2024. *Interactive Learning Environments*, 33(3):1823–1849, 2025.

[2] Zhedong Liu and Haavard Rue. Leave-group-out cross-validation for latent gaussian models. *arXiv preprint arXiv:2210.04482*, 2022.

[3] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. *Advances in neural information processing systems*, 31, 2018.