Rapport Scientifique

ING4 : Mineure Recherche

Détection de Stress Cognitif Académique via Apprentissage Automatique

Présenté par :

Axel Bröns, Anas Boutaleb, Omar El Alami El Fellousse

Sous la direction de :

Guilherme Medeiros Machado, Aakash Soni, Faiza Belbachir

2025/2026

Table des matières

1 Introduction **2**

2 État de l'art **2**
2.1 Définition du Stress Académique 2
2.2 Approches basées sur l'Apprentissage Automatique Classique (Machine Learning) 3
2.3 Approches basées sur l'Apprentissage Profond (Deep Learning) 3
2.4 Synthèse et limites de la littérature 4

3 Matériels & Protocole Expérimental **4**
3.1 Participants 4
3.2 Matériel 4
3.3 Protocole expérimental 5

4 Traitement du Signal **6**
4.1 Le Fenêtrage (Windowing) 6
4.2 Extraction de Features (NeuroKit2) 7
4.2.1 Signaux Cardiovasculaires (ECG) 7
4.2.2 Activité Électrodermale (EDA) 7

5 Modélisation et Apprentissage Automatique **8**
5.1 Normalisation intra-sujet 9
5.2 Validation LOGO (Leave-One-Group-Out) 9
5.3 Apprentissage Ensembliste 10

6 Résultats **11**
6.1 Évaluation comparative des algorithmes (Benchmark) 11
6.2 Analyse fine des performances de CatBoost 11
6.3 Interprétabilité et Importance des Caractéristiques (XAI) 12

7 Discussion **13**
7.1 Interprétation Physiologique 13
7.2 Identification et Correction des Biais Méthodologiques 14
7.3 Limites 14

8 Conclusion et Perspectives **15**
8.1 Conclusion Générale 15
8.2 Travaux futurs et Perspectives 15

1 Introduction

Le stress académique est aujourd'hui un enjeu majeur dans le milieu scolaire et universitaire. Bien plus qu'un simple inconfort passager, il peut avoir des conséquences importantes sur la santé mentale et physique des étudiants, allant du décrochage scolaire jusqu'à des troubles plus graves. Dans ce contexte, comprendre, mesurer et anticiper le stress devient une problématique essentielle, à la fois pour améliorer les conditions d'apprentissage et pour accompagner les étudiants de manière plus adaptée.

Traditionnellement, l'évaluation du stress repose sur des méthodes subjectives, telles que les questionnaires ou les observations comportementales. Cependant, ces approches présentent des limites importantes, notamment en termes de précision et de réactivité. Avec l'émergence des technologies numériques et des capteurs physiologiques, il est désormais possible d'exploiter des données objectives issues du corps humain, comme la fréquence cardiaque, l'activité électrodermale ou encore les signaux cérébraux. Ces signaux permettent de mieux caractériser les états de stress et ouvrent la voie à des analyses plus fines et automatisées.

Parallèlement, les avancées en apprentissage automatique offrent des outils puissants pour analyser ces données complexes. De nombreux travaux récents montrent que la combinaison de signaux physiologiques avec des modèles de machine learning ou de deep learning permet d'atteindre des performances intéressantes dans la détection du stress. Néanmoins, ces approches présentent encore plusieurs limites, notamment liées à la taille réduite des échantillons, au manque de diversité des données et aux difficultés de généralisation des modèles à de nouveaux individus.

Dans ce contexte, la problématique centrale de ce projet est la suivante : comment détecter efficacement le stress académique à partir de signaux physiologiques en utilisant des techniques d'apprentissage automatique ? L'objectif est donc de proposer une approche permettant non seulement de mesurer le stress, mais également de contribuer à sa compréhension et à sa prévention.

Pour répondre à cette problématique, ce travail s'appuie sur la collecte de données physiologiques issues de capteurs, leur traitement et l'extraction de caractéristiques pertinentes, ainsi que l'application de modèles de classification. L'enjeu est de construire un pipeline complet capable de discriminer différents états de stress de manière fiable.

Ce rapport est structuré de la manière suivante : dans un premier temps, les matériels et méthodes utilisés seront présentés, puis les résultats obtenus seront analysés et discutés. Enfin, une conclusion viendra synthétiser les principaux apports du projet et proposer des perspectives d'amélioration.

2 État de l'art

2.1 Définition du Stress Académique

Le stress est défini par McEwen (1998) comme un état de menace, réelle ou perçue, pour l'homéostasie de l'organisme, nécessitant une réponse adaptative pour rétablir l'équilibre. Dans le milieu académique, ce phénomène est particulièrement critique. Selon une revue systématique de S. Liu et al. (2025), le stress scolaire prolongé entraîne des conséquences graves telles que le décrochage scolaire, des problèmes de santé chroniques, et peut même

présenter des risques vitaux pour les étudiants. Face à ce constat, l'intégration de l'intelligence artificielle et de l'analyse multimodale des signaux physiologiques offre de nouvelles perspectives pour détecter et prévenir de manière proactive la surcharge mentale.

2.2 Approches basées sur l'Apprentissage Automatique Classique (Machine Learning)

L'utilisation de capteurs physiologiques embarqués (wearables) couplée à des modèles de Machine Learning traditionnels constitue une première approche largement explorée. Lalwani et Ferdowsi (2025) ont étudié la prédiction du stress lors de trois sessions d'examens (Midterm 1, Midterm 2, Final) auprès de 10 étudiants équipés de bracelets Empatica E4. Ils ont collecté 6 signaux physiologiques (fréquence cardiaque, température, EDA, IBI, accélérométrie) segmentés en fenêtres d'une minute. Parmi les 5 modèles testés, l'algorithme CatBoost s'est avéré le plus performant, atteignant un F1-Score d'environ 78% lors de l'examen final. Cependant, cette étude souligne une capacité de généralisation limitée face à des tâches de plus en plus complexes et s'appuie sur un échantillon restreint comportant un déséquilibre hommes/femmes. De manière similaire, Garg et al. (2021) ont extrait des caractéristiques statistiques sur des fenêtres de 10 secondes à partir du dataset WESAD (15 participants). Leur modèle Random Forest a plafonné à un F1-Score d'environ 83%, démontrant les limites des modèles classiques pour des classifications multi-classes fines.

2.3 Approches basées sur l'Apprentissage Profond (Deep Learning)

Pour pallier les limites du Machine Learning classique, des travaux récents se sont tournés vers l'Apprentissage Profond, exploitant des architectures complexes ou des transformations de données innovantes. Modi et al. (2025) ont exploré la détection du stress à l'aide de signaux électroencéphalographiques (EEG) pour classifier trois états : normal, légèrement stressé, et hautement stressé. Après une réduction de dimensionnalité par PCA (passant de 988 à 475 features), ils ont comparé 8 architectures de Deep Learning. Leur modèle hybride combinant CNN et MLP a obtenu d'excellents résultats avec un F1-Score d'environ 99%. Toutefois, cette expérimentation ne repose que sur les données de 4 étudiants, ce qui expose fortement le modèle au surapprentissage (overfitting) et souffre d'un manque criant de diversité.

Une approche alternative proposée par Yang et al. (2025) consiste à transformer des signaux physiologiques unidimensionnels (EDA, BVP, respiration, température et accéléromètre du dataset WESAD) en images bidimensionnelles à l'aide de méthodes telles que GASF, GADF et MTF. Ces images alimentent ensuite un réseau neuronal convolutif (CNN) doté de six couches.La combinaison des signaux EDA, accéléromètre, BVP et température a permis d'atteindre une précision de 90,96% et un F1-Score de 91,67%. Bien que très performant, ce pipeline de traitement est critiqué pour sa complexité de mise en œuvre, son coût computationnel élevé, et l'utilisation d'un jeu de données déséquilibré. Enfin, Q. Chen et Lee (2023) ont obtenu un F1-Score d'environ 95% via des modèles de Deep Learning appliqués à 30 étudiants résolvant des Sudokus, bien que le cadre de cette expérience soit considéré comme peu naturel.

2.4 Synthèse et limites de la littérature

La revue de la littérature actuelle met en évidence deux consensus majeurs : la combinaison de multiples signaux physiologiques (tels que l'EDA, le rythme cardiaque ou l'EEG) constitue une mesure fiable du stress, et les architectures hybrides de Deep Learning semblent aujourd'hui dominer en termes de performances brutes. Néanmoins, les études existantes se heurtent systématiquement à trois limites fondamentales qui freinent leur déploiement opérationnel :

1. **L'insuffisance des données** : La majorité des recherches reposent sur des échantillons très restreints (souvent moins de 15 individus, voire 4 dans certaines études), compromettant la représentativité statistique.
2. **Le manque de réalisme** : Les protocoles sont souvent réalisés dans des cadres de laboratoire très artificiels (résolution de grilles de Sudoku, expériences statiques) qui peinent à reproduire la charge mentale réelle d'un environnement académique.
3. **Le défi de la généralisation** : La variabilité inter-individuelle des réponses physiologiques (notamment l'activité électrodermale) rend extrêmement difficile l'application de ces modèles pré-entraînés sur de nouveaux étudiants n'ayant pas participé à l'apprentissage.

3 Matériels & Protocole Expérimental

Afin de concevoir un système capable de détecter et d'isoler la signature physiologique spécifique au stress académique, une campagne d'acquisition de données a été menée. L'objectif de ce protocole est de générer des états de repos, de charge mentale et d'activation physique distincts, permettant par la suite d'entraîner des modèles d'apprentissage automatique.

3.1 Participants

L'expérience a été menée sur une cohorte initiale composée de trois étudiants volontaires. Cette taille d'échantillon, bien que restreinte, a été jugée suffisante pour une preuve de concept (POC) visant à évaluer la faisabilité d'une détection via des capteurs à bas coût. Il est à noter que lors de la phase d'analyse exploratoire des données, les enregistrements de l'un des participants ont révélé un profil physiologique atypique (potentiel profil "non-répondant" sur l'activité électrodermale). Afin de garantir la robustesse de l'apprentissage des algorithmes et d'éviter l'introduction d'un biais, les données de ce sujet ont été exclues de l'entraînement final, recentrant l'analyse sur des signaux exploitables et cohérents.

3.2 Matériel

L'acquisition des signaux physiologiques a été réalisée à l'aide de la plateforme matérielle BITalino (R)evolution. Ce choix technologique répond à la volonté de proposer une solution accessible et potentiellement déployable à grande échelle dans un environnement éducatif.

Deux modalités physiologiques ont été enregistrées simultanément :

— **L'Électrocardiogramme (ECG)** : Les électrodes ont été positionnées sur le torse des participants (figure 1a) afin d'enregistrer l'activité électrique du cœur et d'en déduire par la suite la variabilité de la fréquence cardiaque (HRV).

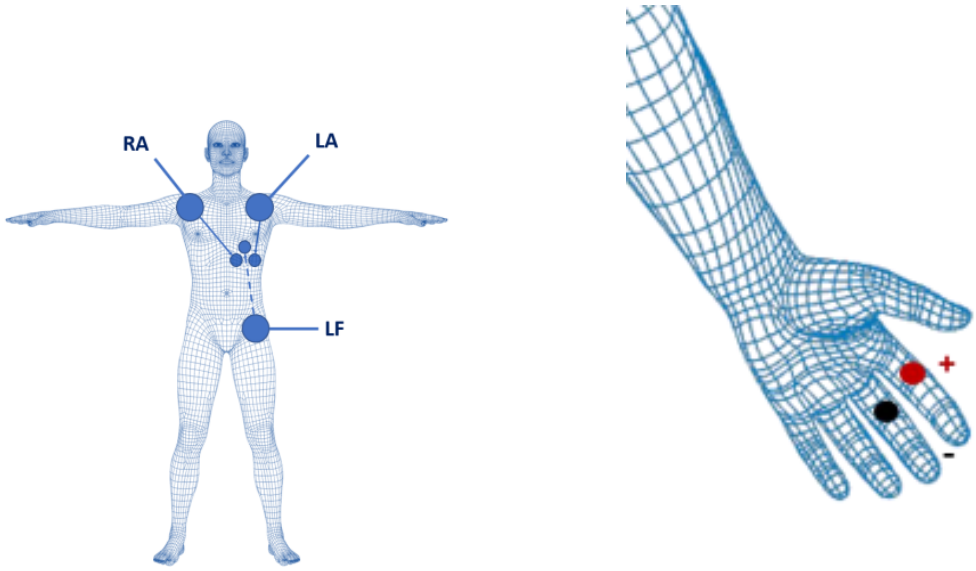

(a) ECG (b) EDA

FIGURE 1 – Placement des électrodes pour l'acquisition des signaux ECG (a) et EDA (b) à l'aide du dispositif BITalino

— **L'Activité Électrodermale (EDA)** : Les capteurs ont été placés sur les phalanges de l'index et du majeur (glandes sudoripares palmaires) (figure 1b) pour mesurer la conductance cutanée, un indicateur direct de l'activation du système nerveux sympathique.

Les données brutes ont été numérisées et transmises en temps réel via le logiciel OpenSignals. La fréquence d'échantillonnage (f_s) a été fixée à 1000 Hz pour les deux capteurs, garantissant une résolution temporelle optimale, particulièrement cruciale pour la détection précise des pics R de l'ECG. Le traitement a ensuite été réalisé sous Python à l'aide de la librairie NeuroKit2.

3.3 Protocole expérimental

Pour contraindre les algorithmes à différencier le stress cognitif pur d'une simple activation cardiovasculaire liée à l'effort, le protocole a été segmenté en trois phases consécutives et chronométrées, d'une durée stricte de 5 minutes chacune :

1. **Phase de référence (Calme)** : Durant les 5 premières minutes, le sujet a été invité à s'asseoir dans un environnement calme, sans stimulation visuelle ou auditive. Cette phase permet d'établir la ligne de base (baseline) physiologique de chaque individu.
2. **Phase de charge mentale (Stress cognitif)** : L'objectif de cette seconde phase de 5 minutes était d'induire un stress psychologique et une forte mobilisation des ressources cognitives. Pour ce faire, deux tâches standardisées ont été imposées aux participants :
   — Des parties de jeux d'échecs en ligne avec une cadence extrêmement rapide (format "Bullet" d'une minute par joueur).
   — Des exercices de mémorisation de longues séries de chiffres sous forte contrainte temporelle.

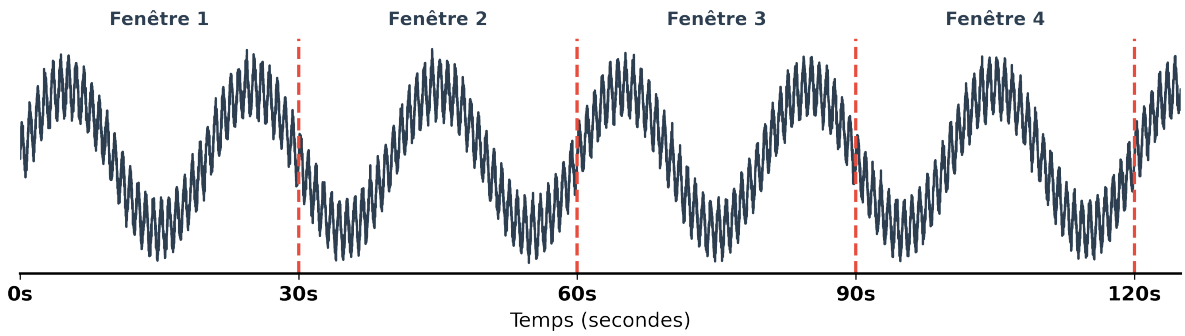

FIGURE 2 – Fenêtrage sur un signal artificiel

3. **Phase d'activation physique (Sport)** : La dernière phase de 5 minutes consistait en un effort physique (activité sportive). Cette étape est fondamentale dans notre méthodologie : elle agit comme un "piège" pour l'algorithme en générant une forte élévation du rythme cardiaque et de la sudation, forçant ainsi le modèle de Machine Learning à rechercher des micro-variations plus subtiles (comme la rigidité du HRV ou l'amplitude des pics SCR) pour ne pas confondre le sport avec le stress mental.

4 Traitement du Signal

Une fois les signaux physiologiques bruts acquis, une chaîne de traitement systématique a été mise en place afin de transformer ces séries temporelles continues en vecteurs de caractéristiques (features) exploitables par les algorithmes d'apprentissage automatique. Ce processus s'articule autour de deux phases majeures : le fenêtrage glissant et l'extraction de métriques non linéaires via la librairie NeuroKit2.

4.1 Le Fenêtrage (Windowing)

L'analyse de séries temporelles physiologiques nécessite une discrétisation temporelle. Soit $x[n]$ le signal discret acquis à une fréquence d'échantillonnage $f_s = 1000$ Hz. Le signal global a été segmenté en fenêtres disjointes W_i de durée $T = 30$ secondes. Visuellement on peut retrouver chaque fenêtre de 30 secondes sur la Figure 2. D'un point de vue mathématique, la i-ème fenêtre W_i contenant N échantillons est définie par l'ensemble :

$$W_i = \{x[n] \mid i \cdot N \leq n < (i+1) \cdot N\} \tag{1}$$

Avec $N = T \times f_s = 30 \times 1000 = 30\,000$ échantillons par fenêtre. Le choix d'une fenêtre temporelle de 30 secondes constitue un compromis empirique optimal : elle est suffisamment courte pour capturer des réactions physiologiques instantanées (pics de stress) et garantir un temps de latence acceptable pour une application en temps réel, tout en restant suffisamment longue pour permettre le calcul robuste des indicateurs de variabilité de la fréquence cardiaque (HRV) dans le domaine temporel.

Catégorie	Features (Signaux)
ECG	HR_Mean, HRV_RMSSD, HRV_pNN50
EDA	EDA_Mean, SCR_Peaks, SCR_Amplitude_Mean

Table 1 – Extraction des caractéristiques physiologiques.

4.2 Extraction de Features (NeuroKit2)

Pour chaque fenêtre W_i de l'équation 1, l'algorithme extrait des indicateurs physiologiques spécifiques à l'aide des algorithmes de détection de pics intégrés à NeuroKit2. Les caractéristiques extraites se divisent en deux familles, ECG et EDA, comme écris dans le Tableau 1.

4.2.1 Signaux Cardiovasculaires (ECG)

Après un filtrage passe-bande pour éliminer les artefacts de mouvement et l'errance de la ligne de base, l'algorithme détecte les complexes QRS pour isoler les pics R. Soit RR_j la durée en millisecondes du j-ème intervalle entre deux pics R successifs, et K le nombre total de pics dans la fenêtre W_i (équation 1). Trois métriques ont été calculées :

HR_Mean (Fréquence Cardiaque Moyenne) : Reflète l'activation cardiovasculaire globale, particulièrement sensible lors de la phase de sport.

HRV_RMSSD (Root Mean Square of Successive Differences) : C'est le marqueur temporel principal de l'activité du système nerveux parasympathique. Il est défini par la racine carrée de la moyenne des carrés des différences successives des intervalles R-R :

$$\text{RMSSD} = \sqrt{\frac{1}{K-1} \sum_{j=1}^{K-1} (RR_{j+1} - RR_j)^2}$$

HRV_pNN50 : Représente le pourcentage d'intervalles R-R successifs dont la différence absolue excède 50 millisecondes. Une chute du pNN50 est un marqueur fort de la rigidité cardiaque induite par le stress cognitif :

$$\text{pNN50} = \frac{\sum_{j=1}^{K-1} \mathbb{I}(|RR_{j+1} - RR_j| > 50 \text{ ms})}{K-1} \times 100$$

(Où $\mathbb{I}$ est la fonction indicatrice valant 1 si la condition est vérifiée, 0 sinon).

4.2.2 Activité Électrodermale (EDA)

Le signal EDA est décomposé en deux composantes physiologiques distinctes : la conductance cutanée tonique (SCL, composante lente) et la conductance cutanée phasique (SCR, réponses rapides).

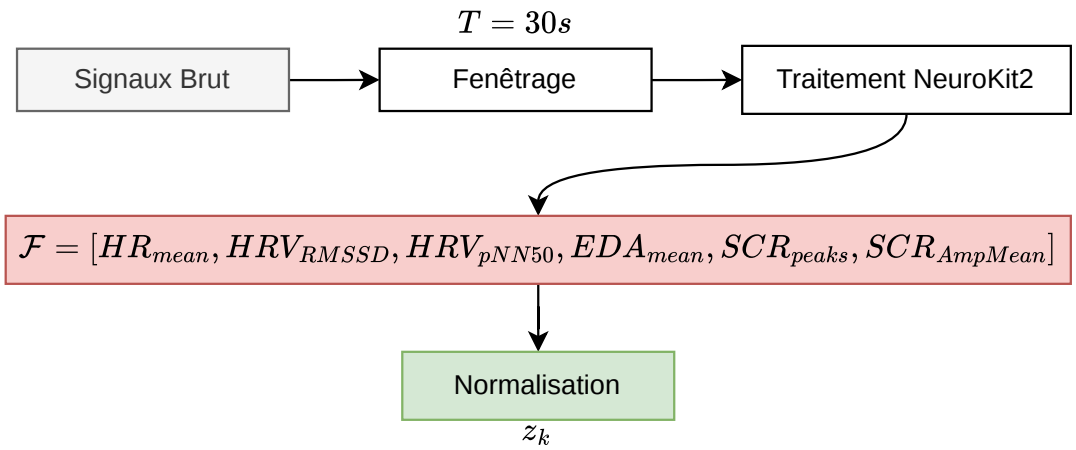

FIGURE 3 – Pipeline de la data preparation

EDA_Mean (Niveau Tonique) : Représente la moyenne globale de la conductance sur la fenêtre.

$$\mu_{EDA} = \frac{1}{N} \sum_{n=0}^{N-1} x_{EDA}[n]$$

Note méthodologique : Bien que cette métrique capture l'accumulation de la sudation, elle est sujette à une forte dérive temporelle qu'on va détailler par la suite dans la section 7.2.

SCR_Peaks (Nombre de pics phasiques) : Comptabilise le nombre de micro-pulsations des glandes sudoripares palmaires déclenchées par le système nerveux sympathique face à un stimulus stressant.

SCR_Amplitude_Mean : Calcule l'intensité moyenne (en micro-Siemens, μS) de ces pics phasiques. C'est un indicateur ultra-réactif de la charge mentale, indépendant du temps écoulé.

5 Modélisation et Apprentissage Automatique

L'objectif de cette phase est de construire une fonction de projection capable d'associer un vecteur d'indicateurs physiologiques à un état cognitif ou physique donné.

Soit $\mathcal{D} = \{(\mathbf{x}_i, y_i, g_i)\}_{i=1}^{M}$ notre jeu de données expérimental composé de M fenêtres d'observation. Pour chaque observation i on a $\mathbf{x}_i \in \mathbb{R}^d$ qui représente le vecteur des d caractéristiques physiologiques extraites ($d = 6$, dans notre cas d'après le Tableau 1), $y_i \in \mathcal{Y} = \{\text{Calme}, \text{Stress}, \text{Sport}\}$ correspond à l'étiquette de la classe et $g_i \in \mathcal{S} = \{s_1, s_2, s_3\}$ identifie le sujet source de l'observation.

5.1 Normalisation intra-sujet

L'une des difficultés majeures de l'analyse des signaux physiologiques, et de l'activité électrodermale en particulier, réside dans la variance inter-individuelle. La ligne de base (baseline) sudoripare et le rythme cardiaque au repos diffèrent structurellement d'un individu à l'autre. Une normalisation globale sur l'ensemble du jeu de données $\mathcal{D}$ aurait pour effet de noyer les variations relatives sous le poids des différences absolues entre sujets.

Pour pallier ce biais, une normalisation standard intra-sujet (Z-score) a été appliquée. Pour un sujet $k \in \mathcal{S}$, soit $\mathcal{D}^{(k)} = \{\mathbf{x}_i \mid g_i = s_k\}$ le sous-ensemble de ses observations. Pour chaque caractéristique $j \in \{1, \ldots, d\}$, la moyenne empirique $\mu_j^{(k)}$ et l'écart-type $\sigma_j^{(k)}$ sont calculés exclusivement sur $\mathcal{D}^{(k)}$:

$$\mu_j^{(k)} = \frac{1}{|\mathcal{D}^{(k)}|} \sum_{i|g_i=s_k} x_{i,j} \quad \text{et} \quad \sigma_j^{(k)} = \sqrt{\frac{1}{|\mathcal{D}^{(k)}|} \sum_{i|g_i=s_k} (x_{i,j} - \mu_j^{(k)})^2} \tag{2}$$

Chaque composante $x_{i,j}$ du vecteur $\mathbf{x}_i$ est ensuite centrée et réduite selon l'équation :

$$z_{i,j} = \frac{x_{i,j} - \mu_j^{(g_i)}}{\sigma_j^{(g_i)}} \tag{3}$$

Cette transformation garantit que chaque caractéristique possède une moyenne nulle et une variance unitaire pour chaque participant, forçant ainsi les algorithmes d'apprentissage à se baser sur les dynamiques physiologiques (les variations d'état) plutôt que sur les valeurs absolues.

5.2 Validation LOGO (Leave-One-Group-Out)

Dans l'analyse de séries temporelles physiologiques, des fenêtres consécutives présentent une forte autocorrélation. L'utilisation d'une validation croisée standard (K-Fold) entraînerait une "fuite de données" (data leakage), où des segments quasi-identiques se retrouveraient à la fois dans les ensembles d'entraînement et de test, menant à une surestimation artificielle des performances.

Pour garantir la capacité de généralisation du modèle à un individu inconnu, une validation croisée de type Leave-One-Group-Out (LOGO) (Z. Liu et Rue 2022) a été implémentée de manière stricte. Soit $\mathcal{S} = \{s_1, \ldots, s_N\}$ l'ensemble des N sujets. À chaque itération $n \in \{1, \ldots, N\}$, le jeu de données est partitionné respectivement en ensemble d'entraînement et en ensemble de test de la manière suivante :

$$D_{train}^{(n)} = \{(\mathbf{z}_i, y_i) \mid g_i \neq s_n\} \quad \text{et} \quad D_{test}^{(n)} = \{(\mathbf{z}_i, y_i) \mid g_i = s_n\} \tag{4}$$

À l'issue des N itérations, le modèle a été évalué sur chaque sujet sans jamais l'avoir rencontré durant son optimisation. La métrique de performance finale (ex : F1-Score) est obtenue par la moyenne des métriques calculées sur chaque sous-ensemble $D_{test}^{(n)}$.

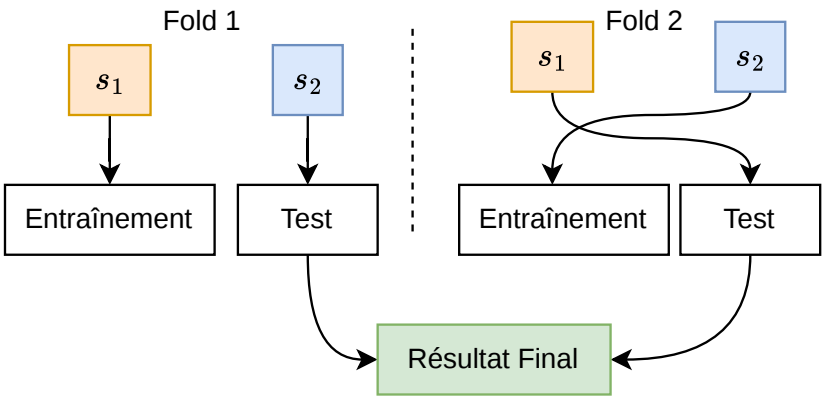

FIGURE 4 – Validation LOGO, avec $\mathcal{S} = \{s_1, s_2, \ldots, s_N\}$ l'ensemble des sujets et ici $N = 2$ donc $n = 2$ le nombre de folds et d'itération.

5.3 Apprentissage Ensembliste

Afin d'estimer la fonction $\hat{f} : \mathbb{R}^d \to \mathcal{Y}$ minimisant l'erreur de classification généralisée, plusieurs architectures ont été évaluées, allant des modèles linéaires (Régression Logistique, SVM linéaire) aux modèles ensemblistes basés sur des arbres de décision (Random Forest, XGBoost, CatBoost).

Compte tenu de la non-linéarité inhérente aux signaux biomédicaux, la famille des algorithmes de Gradient Boosting s'est avérée la plus appropriée. De manière formelle, ces modèles construisent une approximation additive sous la forme d'un ensemble de T arbres de décision. La prédiction pour une observation $\mathbf{z}_i$ est donnée par :

$$\hat{y}_i = \sum_{t=1}^{T} h_t(\mathbf{z}_i) \tag{5}$$

Où $h_t \in \mathcal{H}$ appartient à l'espace des arbres de régression/classification. À chaque itération t, un nouvel arbre h_t est entraîné pour minimiser une fonction de perte $\mathcal{L}$ multiclasse (telle que la Multinomial Log-Loss) par rapport au pseudo-résidu de l'étape précédente.

Le choix de CatBoost : Parmi les algorithmes testés, CatBoost (PROKHORENKOVA et al. 2018) s'est distingué empiriquement. Outre sa gestion native des variables catégorielles, sa force théorique réside dans l'utilisation exclusive d'arbres symétriques dits "oblivieux" (oblivious decision trees). Contrairement aux arbres de XGBoost (T. CHEN et al. 2015) qui peuvent croître de manière asymétrique, les arbres de CatBoost appliquent la même condition de scission (split) sur tous les nœuds d'un même niveau de profondeur. Cette contrainte architecturale agit comme un puissant régularisateur mathématique, prévenant efficacement le phénomène de surapprentissage (overfitting), un défi critique lors du traitement de jeux de données de taille restreinte comme le nôtre.

Table 2 – Comparaison des performances des modèles de classification

Modèle	Accuracy	Precision	Recall	F1-Score
SVM (RBF)	66.10	64.77	66.05	64.66
Régression Logistique	69.49	71.44	69.65	69.57
SVM (Linéaire)	71.19	71.86	71.23	70.99
Random Forest	83.05	84.39	83.33	82.91
XGBoost (T. Chen et al. 2015)	84.75	86.79	85.00	84.26
CatBoost (Prokhorenkova et al. 2018)	**88.14**	**89.78**	**88.33**	**88.15**

6 Résultats

L'évaluation de notre pipeline de traitement (voir Figure 3) et d'apprentissage a été réalisée selon la méthode de validation croisée Leave-One-Group-Out (LOGO) (détaillé dans la section 5.2). Les métriques de performance retenues pour quantifier la robustesse des modèles sont l'Exactitude (Accuracy), la Précision (Precision), le Rappel (Recall) et le F1-Score, calculées en moyenne macroscopique afin de traiter les trois classes (Calme, Stress, Sport) de manière équitable.

6.1 Évaluation comparative des algorithmes (Benchmark)

Une étude comparative a été menée sur six algorithmes de classification, allant des approches linéaires traditionnelles aux méthodes d'apprentissage ensembliste avancées. Les résultats globaux sont synthétisés dans le Tableau 2.

L'analyse de ces résultats met en évidence une dichotomie claire entre les familles d'algorithmes :

Les modèles linéaires et à noyaux (Régression Logistique, SVM) : Ces algorithmes peinent à modéliser la complexité des signaux physiologiques, plafonnant à un F1-Score d'environ 71% pour le SVM linéaire. Ce résultat démontre que la séparation entre les états cognitifs et physiques dans l'espace des caractéristiques physiologiques n'est pas linéairement séparable.

Les modèles ensemblistes basés sur les arbres (Random Forest, XGBoost, CatBoost) : Ces méthodes capturent efficacement les interactions non linéaires entre les variables. L'algorithme CatBoost s'impose nettement comme le modèle le plus performant de notre étude, atteignant une exactitude de 88,14% et un F1-Score de 88,15%. Sa capacité à traiter les ensembles de données de taille modeste tout en limitant le surapprentissage grâce à ses arbres symétriques justifie cette supériorité empirique.

6.2 Analyse fine des performances de CatBoost

Afin de comprendre le comportement prédictif de notre meilleur modèle (CatBoost), la matrice de confusion issue de la validation LOGO a été générée et analysée.

D'après l'observation de la matrice de confusion (Figure 5) révèle plusieurs points majeurs quant à la détectabilité des états physiologiques :

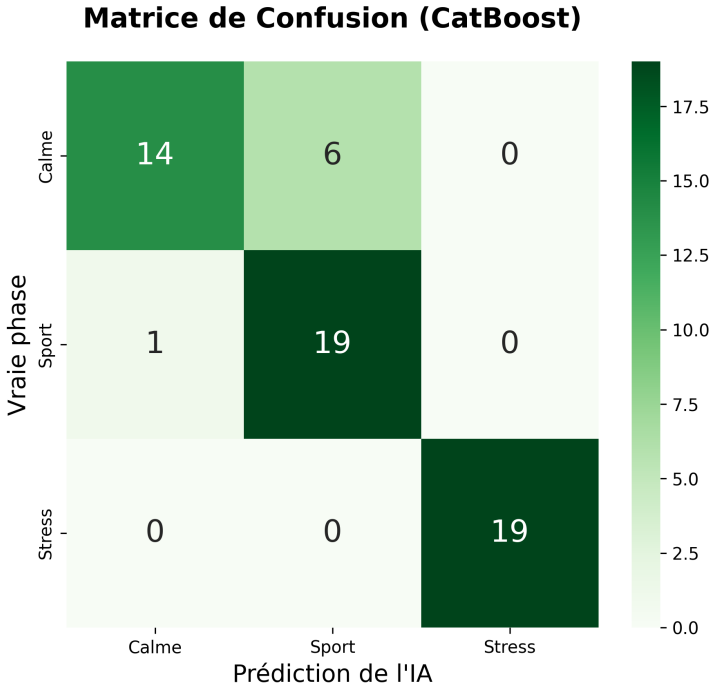

FIGURE 5 – Matrice de confusion pour l'algorithme **CatBoost**

1. **L'isolation parfaite du stress cognitif :** Le résultat le plus probant de cette étude est l'absence totale de confusion concernant la classe "Stress". Le modèle a correctement identifié 100% (19/19) des fenêtres de charge mentale. Il n'a jamais confondu un état de calcul mental avec un effort physique ou un état de repos.
2. **La détection de l'effort physique :** La classe "Sport" est identifiée avec une quasi-perfection (19/20), prouvant que l'élévation brutale du rythme cardiaque est un marqueur univoque pour l'algorithme.
3. **La confusion Calme/Sport :** La seule faiblesse résiduelle du modèle se situe dans la classification de l'état "Calme", où 6 fenêtres ont été faussement prédites comme appartenant à la classe "Sport". Sur le plan physiologique, cette erreur est explicable par l'inertie du corps humain : l'activation cardiovasculaire et sudoripare ne redescend pas instantanément à sa ligne de base après un effort ou une phase d'excitation, créant des fenêtres de transition ambiguës pour l'algorithme.

6.3 Interprétabilité et Importance des Caractéristiques (XAI)

Pour dépasser l'aspect "boîte noire" de l'algorithme CatBoost dans la section 6.2 et valider la pertinence de notre extraction de caractéristiques dans la partie 4.2, nous avons extrait l'importance relative des variables dans le processus de décision du modèle.

L'analyse des contributions révèle que le modèle s'appuie sur une combinaison cohérente de marqueurs cardiovasculaires et électrodermaux, après avoir analysé la Figure 6, on peut noter :

Les marqueurs de l'effort physique : La fréquence cardiaque moyenne (HR_Mean) présente un poids prépondérant, agissant comme le discriminateur principal pour isoler mécaniquement la phase de sport.

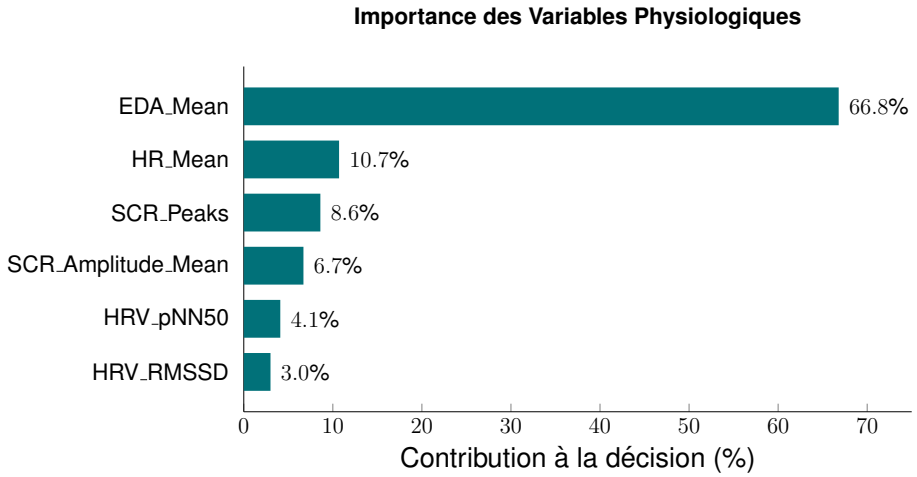

FIGURE 6 – Importance des variables physiologique lors de l'apprentissage de notre modèle CatBoost

Les marqueurs de la charge mentale : Pour différencier le "Calme" du "Stress cognitif", le modèle exploite les variations fines du système nerveux autonome. L'amplitude moyenne des pics de conductance cutanée (SCR_Amplitude_Mean) et le nombre de micro-pulsations (SCR_Peaks) se révèlent être des indicateurs phasiques cruciaux. Contrairement au niveau tonique global (EDA_Mean), ces pics réagissent de manière quasi instantanée à la sollicitation cognitive (calcul mental, résolution d'échecs), confirmant l'hypothèse selon laquelle l'activité des glandes sudoripares palmaires est un marqueur fiable du stress intellectuel.

7 Discussion

Cette étude visait à démontrer la faisabilité d'une détection automatisée du stress académique à l'aide de signaux physiologiques multimodaux et de modèles d'apprentissage automatique. Les performances obtenues, notamment par l'algorithme CatBoost, valident cette preuve de concept. Au-delà des métriques de performance, l'analyse des décisions du modèle soulève des points de discussion cruciaux concernant la physiologie humaine et la méthodologie de recherche.

7.1 Interprétation Physiologique

L'un des défis majeurs de la biométrie est la différenciation entre un stress psychologique (cognitif) et un stress physique (sport). Les modèles ont réussi à bien faire la différence entre les deux états, ce qui confirme les principes de la réactivité du corps gérés par le système nerveux autonome (SNA). Alors que la partie 6 a mis en évidence le poids statistique des différentes caractéristiques, il convient d'en analyser la signification biologique.

L'algorithme a logiquement isolé l'état de "Sport" en s'appuyant quasi exclusivement sur la fréquence cardiaque moyenne (HR_Mean). L'effort physique induit une demande métabolique massive que le cœur compense par une tachycardie prononcée, constituant un signal macroscopique très simple à identifier.

À l'inverse, l'identification du "Stress cognitif" s'est opérée sur des signaux de très faible amplitude. La sollicitation intellectuelle intense (calcul, échecs) active la branche sympathique du SNA, déclenchant les glandes sudoripares palmaires. L'algorithme a su capter cette signature subtile à travers l'amplitude (SCR_Amplitude_Mean) et la fréquence (SCR_Peaks) des micro-pulsations de sueur. Ces résultats confirment qu'une charge mentale pure possède une empreinte physiologique distincte, lisible non pas dans l'accélération globale du métabolisme, mais dans la réactivité instantanée de l'activité électrodermale.

7.2 Identification et Correction des Biais Méthodologiques

La validité d'un modèle d'intelligence artificielle repose sur sa robustesse face aux variables confondantes. Au cours de cette étude, deux biais majeurs ont été identifiés et traités, illustrant les pièges classiques de l'analyse de séries temporelles physiologiques.

Le biais de l'Inertie Sudoripare (Effet Chronomètre) : Lors des premières itérations du modèle, la conductance cutanée moyenne (EDA_Mean) présentait une importance prédictive anormalement élevée (comme dans la Figure 6). L'analyse critique a révélé que la sueur s'accumule naturellement sur la peau au fil de l'expérience, augmentant progressivement le niveau tonique de base. Les phases de notre protocole étant chronologiques, la variable EDA_Mean agissait comme un marqueur temporel déguisé. Le modèle ne détectait plus le stress, il apprenait simplement à "lire l'heure" de l'expérience. La transition vers une extraction de caractéristiques strictement phasiques et non cumulatives (comme les pics SCR) a permis de neutraliser cette fuite de données (data leakage) temporelle.

Le phénomène des "Non-Répondeurs" et des erreurs de mesures : Comme mentionné dans la partie 3.1, les données d'un participant ont dû être exclues. Ce choix n'est pas qu'un simple nettoyage de données, il met en lumière une réalité physiologique bien documentée : le phénomène des "non-répondeurs électrodermaux" (EDA non-responders). Une proportion non négligeable de la population ne manifeste pas (ou très peu) d'augmentation de la conductance cutanée face à un stimulus émotionnel ou cognitif. La présence de ce profil dans notre cohorte rappelle qu'un système de détection de stress universel devra nécessairement intégrer des modalités compensatoires (comme l'EEG ou l'oculométrie) pour pallier ces "silences" physiologiques individuels.

Conformément au dispositif décrit dans la section 3.2, les mesures ont été réalisées via la plateforme BITalino. Il convient toutefois de noter qu'une dégradation de la qualité du signal, notamment lors de la phase d'activation physique, n'est pas exclue en raison d'un possible décollement partiel des électrodes induit par le mouvement.

7.3 Limites

Malgré les résultats prometteurs obtenus en validation croisée (LOGO), la portée de cette recherche doit être nuancée par plusieurs limites structurelles.

1. **Taille de l'échantillon** : L'expérimentation repose sur un échantillon restreint de trois étudiants (réduit à deux pour l'apprentissage final). Bien que la méthode de validation prévienne le surapprentissage sur ces sujets spécifiques, la taille de la cohorte ne permet pas d'affirmer que le modèle généralisera ses prédictions à

l'ensemble d'une population étudiante présentant une vaste diversité de lignes de base physiologiques.

2. **Environnement de laboratoire** : Le protocole expérimental a été mené dans un cadre très contrôlé, alternant des phases strictes de 5 minutes dédiées exclusivement à une tâche. Or, dans un environnement académique réel (une salle de classe ou une salle d'examen), le stress n'est pas compartimenté. Les étudiants subissent une superposition d'états : ils peuvent être concentrés, puis relâchés, bouger sur leur chaise (générant des artefacts de mouvement), ou ressentir de l'ennui. Le modèle actuel n'a pas été confronté à ce "bruit" contextuel inhérent à la vie réelle.
3. **Absence de lissage temporel** : Le pipeline de décision actuel juge chaque fenêtre de 30 secondes de manière totalement indépendante. Or, l'état psychologique d'un individu possède une inertie temporelle (le stress ne disparaît pas en une seconde). L'absence d'une approche contextuelle (comme une moyenne mobile des prédictions ou l'utilisation de réseaux récurrents type LSTM) limite la fluidité et la fiabilité de la classification en continu.

8 Conclusion et Perspectives

8.1 Conclusion Générale

Cette étude avait pour objectif de concevoir un système automatisé capable de détecter et de classifier le stress académique en exploitant des signaux physiologiques multimodaux (ECG et EDA, détaillés dans la section 4.2) acquis via un dispositif matériel à bas coût (BITalino, voir section 3.2). Les travaux menés ont permis de valider avec succès cette preuve de concept.

En surmontant les biais liés à l'inertie physiologique (notamment la dérive temporelle de la conductance cutanée tonique), notre pipeline de traitement (Figure 3) a pu isoler les biomarqueurs pertinents de la charge mentale et de l'activation métabolique. L'évaluation rigoureuse des modèles par validation croisée Leave-One-Group-Out (LOGO, Section 5.2) a démontré que l'algorithme CatBoost (Partie 6.2) s'imposait comme la solution la plus robuste pour ce problème de classification multiclasse (Calme, Stress, Sport).

Avec une exactitude de 88,14% et un F1-Score de 88,15% (comme le montre le Tableau 2) , le modèle a prouvé sa capacité de généralisation sur des sujets inédits , en apprenant à différencier l'emballement cardiaque lié à l'effort physique des micro-pulsations sudoripares générées par une intense sollicitation cognitive. Ce résultat confirme que l'intelligence artificielle, couplée à une ingénierie des caractéristiques (Feature Engineering) physiologiquement pertinente, offre une voie prometteuse pour le suivi objectif de la santé mentale des étudiants.

8.2 Travaux futurs et Perspectives

Bien que les résultats de cette phase exploratoire soient concluants, le passage d'une preuve de concept en laboratoire à un outil de prévention déployable à grande échelle nécessite des développements ultérieurs. Plusieurs axes d'amélioration ont été identifiés pour la suite de ce projet :

Élargissement et diversification de la cohorte : L'échantillon actuel étant restreint à trois étudiants , la priorité absolue du prochain semestre sera d'organiser une campagne d'acquisition de données massive. L'intégration de profils physiologiques variés permettra de consolider la robustesse de l'algorithme face à la variabilité inter-individuelle, et notamment de mieux appréhender le phénomène des "non-répondeurs" électrodermaux.

Déploiement en conditions réelles : Le protocole actuel, bien que standardisé, reste limité par son environnement de laboratoire et ses cadences strictes de 5 minutes. Les futurs travaux devront appliquer ce protocole dans de véritables conditions de classe ou d'examen. L'objectif sera de tester la résilience du modèle face aux superpositions d'états (ex : un étudiant stressé qui se déplace) et aux artefacts de mouvement inhérents à la vie courante.

Intégration d'une dimension temporelle (Lissage et Deep Learning) : Actuellement, le modèle classifie chaque fenêtre de 30 secondes de manière isolée. Pour mieux refléter l'inertie des états psychologiques, de futures itérations algorithmiques pourraient intégrer un lissage temporel des prédictions (moyenne mobile) ou explorer des architectures de réseaux de neurones récurrents (RNN ou LSTM), reconnues dans la littérature pour leur excellence dans le traitement séquentiel des séries temporelles physiologiques.

Création d'un outil d'assistance pédagogique : À terme, la finalité de ce projet est de traduire ces prédictions algorithmiques en un tableau de bord intuitif. Cet outil permettrait aux équipes enseignantes de visualiser le niveau de surcharge cognitive globale d'une classe en temps réel , offrant ainsi la possibilité d'adapter dynamiquement le rythme pédagogique et de prévenir activement le décrochage scolaire.

Bibliographie

CHEN, Qicheng et Boon Giin LEE (2023). "Deep Learning Models for Stress Analysis in University Students : A Sudoku-Based Study". In : *Sensors* 23.6099. ISSN : 1424-8220. DOI : 10.3390/s23136099. URL : https://www.mdpi.com/1424-8220/23/13/6099.

CHEN, Tianqi et al. (2015). "Xgboost : extreme gradient boosting". In : *R package version 0.4-2* 1.4, p. 1-4.

GARG, Prerna et al. (2021). "Stress Detection by Machine Learning and Wearable Sensors". In : IUI '21 Companion, p. 43-45. DOI : 10.1145/3397482.3450732. URL : https://doi.org/10.1145/3397482.3450732.

LALWANI, Sham et Saideh FERDOWSI (2025). "Predictive Modelling of Exam Outcomes Using Stress-Aware Learning from Wearable Biosignals". In : *Sensors* 25.5628. ISSN : 1424-8220. DOI : 10.3390/s25185628. URL : https://www.mdpi.com/1424-8220/25/18/5628.

LIU, Sannyuya et al. (2025). "Academic stress detection based on multisource data : a systematic review from 2012 to 2024". In : *Interactive Learning Environments* 33.3, p. 1823-1849. DOI : 10.1080/10494820.2024.2387744. eprint : https://doi.org/10.1080/10494820.2024.2387744. URL : https://doi.org/10.1080/10494820.2024.2387744.

LIU, Zhedong et Haavard RUE (2022). "Leave-group-out cross-validation for latent gaussian models". In : *arXiv preprint arXiv :2210.04482*.

MCEWEN, Bruce S. (1998). "Protective and Damaging Effects of Stress Mediators". In : *New England Journal of Medicine* 338.3, p. 171-179. DOI : 10.1056/NEJM199801153380307. eprint : https://www.nejm.org/doi/pdf/10.1056/NEJM199801153380307. URL : https://www.nejm.org/doi/full/10.1056/NEJM199801153380307.

MODI, Nandini et al. (juill. 2025). "Physiological signal-based mental stress detection using hybrid deep learning models". In : *Discover Artificial Intelligence* 5. DOI : 10.1007/s44163-025-00412-8.

PROKHORENKOVA, Liudmila et al. (2018). "CatBoost : unbiased boosting with categorical features". In : *Advances in neural information processing systems* 31.

YANG, Shiqi et al. (juill. 2025). "A deep learning approach to stress recognition through multimodal physiological signal image transformation". In : *Scientific Reports* 15. DOI : 10.1038/s41598-025-01228-3.